UNIVERSIDAD PERUANA UNIÓN (UPEU)

Facultad de Ingeniería y Arquitectura

E.P. Ingeniería de Sistemas



CURSO: Inteligencia Artificial

ESTUDIANTES:

Russbell Daniel Cari Mamani

DOCENTE:

Angel Rosendo Condori Coaquira

ANEXO-INGENERIA Y DICCIONARIO

SOPORTE DEL INFORME

ANEXO A | INGENIERÍA, CALIDAD Y DICCIONARIO DE DATOS

Evidencia de integración ENAHO–ESCALE 2025, trazabilidad del universo analítico y variables usadas en el pipeline.

1. Ficha del dataset consolidado

Aspecto	Valor / evidencia
Base analítica	17.992 filas × 109 columnas
Llave compuesta	AÑO · MES · CONGLOME · VIVIENDA · HOGAR · UBIGEO · CODPERSO
Duplicados de llave	0
Conglomerados	4.116
Columnas con nulos	40 de 109
Total de valores nulos	303.620 celdas
Resultado	P314A=2 (no uso último mes) entre asistentes 6–17 años
Prevalencia no ponderada	25,64 %

2. Ruta de integración y validación

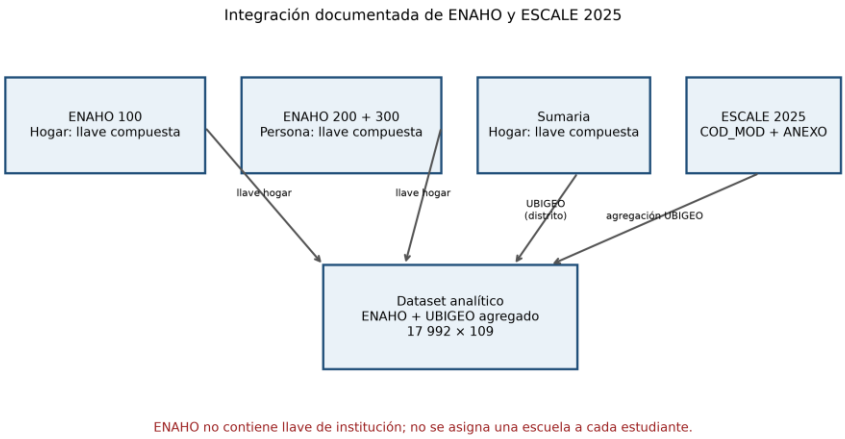


Figura A1. Diagrama del flujo de integración; se documenta el carácter distrital de ESCALE.

Las tablas personales ENAHO se integran con llaves compuestas; las viviendas y hogares se conectan con módulos agregados por hogar. La parte ESCALE vincula Matrícula y Padrón por COD_MOD+ANEXO; antes de unir a ENAHO se agrega por UBIGEO. La auditoría detectó 54.038 servicios educativos compatibles, con 54.038 coincidencias en el conjunto preparado. Padlocal presenta 69.642 locales únicos; 69.356 CODLOCAL comunes con Padrón.

La asociación geográfica no permite conocer a qué centro educativo asiste cada persona ENAHO. El archivo Padlocal disponible carece de coordenadas numéricas y altitud; el Padrón puede aportar promedios de coordenadas donde existen. No debe presentarse infraestructura por colegio como una observación individual.

3. Controles anti-fuga de información

Split externo GroupShuffleSplit, 20 % de prueba; 14.407 train/3.585 test; 3.292/824 conglomerados; cero intersecciones.

Validación interna GroupKFold de tres pliegues por CONGLOME; sin mezcla de conglomerados en entrenamiento/validación.

Preprocesamiento Imputación, escalado y One-Hot dentro de pipelines ajustados con entrenamiento de cada fold.

Exclusiones directas P307, P314A y preguntas condicionadas P314B, P314D, P316 quedan fuera del modelo clasificador.

Ponderación FACTOR07 y manejo del desbalance según código y reportes; cifras ponderadas y conteos no ponderados diferenciados.

4. Principales faltantes (selección)

Variable	Nulos	% de nulos
P316C1	15396	85,6 %
P316C2	15396	85,6 %
P316C3	15396	85,6 %
P316C4	15396	85,6 %
P316C5	15396	85,6 %
P316C6	15396	85,6 %
P316C7	15396	85,6 %
P316C8	15396	85,6 %
P316C9	15396	85,6 %
P316C10	15396	85,6 %
tic_habilidades_digitales_n	15396	85,6 %
P316B	11989	66,6 %

Las ausencias en preguntas TIC son particularmente relevantes por las rutas condicionales del cuestionario. No se interpreta cada NA como una negativa y la imputación predictiva se realiza solo dentro del entrenamiento.

5. Diccionario completo de variables (109 campos)

La tabla se transcribe del diccionario CSV de las evidencias; las descripciones se mantienen en su alcance original. Los porcentajes corresponden al dataset analítico de 17.992 registros y no son tasas poblacionales.

Campo	Descripción / codificación	Falt.
AÑO	Año de la encuesta ENAHO.	0,0 %
MES	Mes de entrevista de la ENAHO.	0,0 %
CONGLOME	Identificador del conglomerado muestral; unidad de separación entre entrenamiento y prueba.	0,0 %
VIVIENDA	Identificador de vivienda dentro del conglomerado.	0,0 %
HOGAR	Identificador de hogar dentro de la vivienda.	0,0 %
UBIGEO	Código geográfico de ubicación; llave para agregar contexto ESCALE distrital.	0,0 %
CODPERSO	Identificador de persona dentro del hogar.	0,0 %
P203	Relación de parentesco con la persona de referencia del hogar.	0,0 %
P207	Sexo de la persona entrevistada.	0,0 %
P208A	Edad en años cumplidos.	0,0 %
P300A	Lengua materna aprendida en la niñez: 1=quechua, 2=aimara, 3=otra nativa, 4=castellano, 6=portugués, 7=otra extranjera, 8=no escucha/habla, 9=lengua de señas, 10=ashaninka, 11=awajún/awarún, 12=shipibo-konibo, 13=shawi, 14=matsigenka, 15=achuar.	0,0 %
P306	Matrícula en un centro o programa educativo durante el año de referencia (1=sí, 2=no).	0,0 %
P307	Asistencia actual a un centro o programa educativo (1=sí, 2=no); define población y se excluye de predictores.	0,0 %
P308A	Nivel en que está matriculada la persona (1=inicial, 2=primaria, 3=secundaria, 4=superior no universitaria, 5=universitaria, 6=maestría/doctorado, 7=básica especial).	0,0 %
P308B	Año/grado de estudios en que está matriculada la persona.	0,0 %
P308C	Grado de estudios de primaria; se usa junto con P308B para edad normativa y rezago.	50,2 %

Campo	Descripción / codificación	Falt.
P314A	Uso de Internet durante el mes anterior (1=sí, 2=no); define el resultado y se excluye de predictores.	0,0 %
FACTOR07	Factor anual de expansión ENAHO basado en proyecciones CPV-2007; ponderador cuando el estimador lo admite.	0,0 %
P314D	Frecuencia de uso de Internet: 1=diaria, 2=semanal, 3=mensual, 4=cada dos meses o más; descriptiva y usada únicamente en clustering, no en clasificación supervisada.	25,6 %
P316B	Uso de computadora, laptop, tablet o similar en los últimos tres meses (1=sí, 2=no).	66,6 %
P314B$1	Código de respuesta de lugar de uso de Internet: 1 corresponde a hogar; 0=no marcó el lugar; descriptiva, excluida del modelo por condicionarse al uso.	25,6 %
P314B$2	Código de respuesta de lugar de uso de Internet: 2 corresponde a trabajo; 0=no marcó el lugar; descriptiva, excluida del modelo por condicionarse al uso.	25,6 %
P314B$3	Código de respuesta de lugar de uso de Internet: 3 corresponde a centro_educativo; 0=no marcó el lugar; descriptiva, excluida del modelo por condicionarse al uso.	25,6 %
P314B$4	Código de respuesta de lugar de uso de Internet: 4 corresponde a cabina_publica; 0=no marcó el lugar; descriptiva, excluida del modelo por condicionarse al uso.	25,6 %
P314B$5	Código de respuesta de lugar de uso de Internet: 5 corresponde a casa_otra_persona; 0=no marcó el lugar; descriptiva, excluida del modelo por condicionarse al uso.	25,6 %
P314B$6	Código de respuesta de lugar de uso de Internet: 6 corresponde a otro_lugar; 0=no marcó el lugar; descriptiva, excluida del modelo por condicionarse al uso.	25,6 %
P314B$7	Código de respuesta de lugar de uso de Internet: 7 corresponde a acceso_movil; 0=no marcó el lugar; descriptiva, excluida del modelo por condicionarse al uso.	25,6 %

Continuación del diccionario de variables.

Campo	Descripción / codificación	Falt.
P316$1	Ítem 1 de propósito de uso de Internet (1=sí, 2=no); descriptivo, excluido del modelo por riesgo de fuga.	25,6 %
P316$2	Ítem 2 de propósito de uso de Internet (1=sí, 2=no); descriptivo, excluido del modelo por riesgo de fuga.	25,6 %
P316$3	Ítem 3 de propósito de uso de Internet (1=sí, 2=no); descriptivo, excluido del modelo por riesgo de fuga.	25,6 %
P316$4	Ítem 4 de propósito de uso de Internet (1=sí, 2=no); descriptivo, excluido del modelo por riesgo de fuga.	25,6 %
P316$5	Ítem 5 de propósito de uso de Internet (1=sí, 2=no); descriptivo, excluido del modelo por riesgo de fuga.	25,6 %
P316$6	Ítem 6 de propósito de uso de Internet (1=sí, 2=no); descriptivo, excluido del modelo por riesgo de fuga.	25,6 %
P316$7	Ítem 7 de propósito de uso de Internet (1=sí, 2=no); descriptivo, excluido del modelo por riesgo de fuga.	25,6 %
P316$8	Ítem 8 de propósito de uso de Internet (1=sí, 2=no); descriptivo, excluido del modelo por riesgo de fuga.	25,6 %
P316$9	Ítem 9 de propósito de uso de Internet (1=sí, 2=no); descriptivo, excluido del modelo por riesgo de fuga.	25,6 %
P316$10	Ítem 10 de propósito de uso de Internet (1=sí, 2=no); descriptivo, excluido del modelo por riesgo de fuga.	25,6 %
P316$11	Ítem 11 de propósito de uso de Internet (1=sí, 2=no); descriptivo, excluido del modelo por riesgo de fuga.	25,6 %
P316$12	Ítem 12 de propósito de uso de Internet (1=sí, 2=no); descriptivo, excluido del modelo por riesgo de fuga.	25,6 %
P316C1	Tarea informática de habilidades digitales declarada (P316C1, 1=sí, 2=no); contribuye al conteo predictor exploratorio.	85,6 %

Campo	Descripción / codificación	Falt.
P316C2	Tarea informática de habilidades digitales declarada (P316C2, 1=sí, 2=no); contribuye al conteo predictor exploratorio.	85,6 %
P316C3	Tarea informática de habilidades digitales declarada (P316C3, 1=sí, 2=no); contribuye al conteo predictor exploratorio.	85,6 %
P316C4	Tarea informática de habilidades digitales declarada (P316C4, 1=sí, 2=no); contribuye al conteo predictor exploratorio.	85,6 %
P316C5	Tarea informática de habilidades digitales declarada (P316C5, 1=sí, 2=no); contribuye al conteo predictor exploratorio.	85,6 %
P316C6	Tarea informática de habilidades digitales declarada (P316C6, 1=sí, 2=no); contribuye al conteo predictor exploratorio.	85,6 %
P316C7	Tarea informática de habilidades digitales declarada (P316C7, 1=sí, 2=no); contribuye al conteo predictor exploratorio.	85,6 %
P316C8	Tarea informática de habilidades digitales declarada (P316C8, 1=sí, 2=no); contribuye al conteo predictor exploratorio.	85,6 %
P316C9	Tarea informática de habilidades digitales declarada (P316C9, 1=sí, 2=no); contribuye al conteo predictor exploratorio.	85,6 %
P316C10	Tarea informática de habilidades digitales declarada (P316C10, 1=sí, 2=no); contribuye al conteo predictor exploratorio.	85,6 %
DOMINIO	Dominio geográfico de la muestra ENAHO.	0,0 %
ESTRATO	Estrato muestral ENAHO; base de la derivación del indicador rural.	0,0 %
P110	Fuente principal de abastecimiento de agua del hogar; según diccionario, códigos 1 y 2 representan red pública.	0,0 %
P110A1	Hogar tiene agua potable (1=sí, 2=no).	16,7 %
P111A	Tipo de servicio higiénico del hogar; códigos 1 y 2 representan conexión a red pública.	0,0 %

Continuación del diccionario de variables.

Campo	Descripción / codificación	Falt.
P1121	Indicador de alumbrado del hogar mediante electricidad (0=no, 1=sí); no representa acceso a Internet.	0,0 %
P1144	Indicador de conexión a Internet fija o móvil en el hogar (0=no, 1=sí).	0,0 %
MIEPERHO	Número de miembros del hogar.	0,0 %
TOTMIEHO	Total de miembros del hogar según Sumaria.	0,0 %
GASHOG2D	Gasto total del hogar según Sumaria.	0,0 %
INGHOG2D	Ingreso total del hogar según Sumaria.	0,0 %
POBREZA	Condición de pobreza monetaria del hogar según Sumaria.	0,0 %
esc_n_escuelas	Número de COD_MOD distintos en UBIGEO.	0,0 %
esc_alumnos	Suma de TALUM en padrón agregado por UBIGEO.	0,0 %
esc_docentes	Suma de TDOC en padrón agregado por UBIGEO.	0,0 %
esc_secciones	Suma de TSEC en padrón agregado por UBIGEO.	0,0 %
esc_prop_gestion_publica	Proporción de registros cuya etiqueta D_GESTION indica gestión pública; NA/0 si el rótulo no está disponible.	0,0 %
esc_lat_media	Media de NLAT_IE de instituciones del distrito, cuando está disponible.	0,0 %
esc_lon_media	Media de NLONG_IE de instituciones del distrito, cuando está disponible.	0,0 %
esc_ratio_alumno_docente	Alumnos / docentes agregados del distrito.	0,0 %
esc_matricula_primaria_2025	Suma distrital del Censo Educativo 2025: C201/3AP (matrícula primaria por grado, sexo y turno),	0,0 %

Campo	Descripción / codificación	Falt.
	enlazada al padrón por COD_MOD+ANEXO.	
esc_matricula_secundaria_2025	Suma distrital del Censo Educativo 2025: C201/3AS (matrícula secundaria por grado, sexo y turno), enlazada al padrón por COD_MOD+ANEXO.	0,0 %
esc_n_locales_padlocal	Número de CODLOCAL distintos observados en Padlocal.dbf por UBIGEO.	0,0 %
edad	Edad en años cumplidos (P208A).	0,0 %
internet_hogar	Variable original ENAHO/ESCALE; ver diccionario anual de la fuente.	0,0 %
exclusion_digital	Indicador: 1=P314A 2 (no usó Internet el mes anterior), 0=P314A 1; población con P307=1 y 6-17 años.	0,0 %
grado_ebr	Grado válido de primaria (P308C) o secundaria (P308B).	4,1 %
edad_normativa	Edad normativa derivada: primaria grado+5; secundaria grado+11.	4,1 %
rezago_escolar_anios	Años de edad por encima de la edad normativa del grado, truncados a cero; faltante si no hay grado válido.	4,1 %
rezago_escolar	Indicador de rezago: edad mayor que la edad normativa; faltante si no hay grado válido.	4,1 %
agua_potable	Indicador de agua potable derivado de P110A1; los demás códigos quedan faltantes.	16,7 %
agua_red_publica	Indicador derivado de P110: fuente de agua en red pública (códigos 1/2).	0,0 %

Continuación del diccionario de variables.

Campo	Descripción / codificación	Falt.
saneamiento_red_publica	Indicador derivado de P111A: servicio higiénico conectado a red pública (códigos 1/2).	0,0 %
tic_frecuencia_uso_cluster	Perfilamiento: P314D (1 diaria, 2 semanal, 3 mensual, 4 cada dos meses o más); 0 si P314A reporta no uso. No se usa en clasificación supervisada.	0,0 %
tic_lugar_1	Uso de Internet en hogar, derivado de P314B$1; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_lugar_2	Uso de Internet en trabajo, derivado de P314B$2; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_lugar_3	Uso de Internet en centro_educativo, derivado de P314B$3; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_lugar_4	Uso de Internet en cabina_publica, derivado de P314B$4; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_lugar_5	Uso de Internet en casa_otra_persona, derivado de P314B$5; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_lugar_6	Uso de Internet en otro_lugar, derivado de P314B$6; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_lugar_7	Uso de Internet en acceso_movil, derivado de P314B$7; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_proposito_1	Propósito de uso de Internet, respuesta afirmativa a P316$1; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_proposito_2	Propósito de uso de Internet, respuesta afirmativa a P316$2; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_proposito_3	Propósito de uso de Internet, respuesta afirmativa a P316$3; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_proposito_4	Propósito de uso de Internet, respuesta afirmativa a P316$4; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_proposito_5	Propósito de uso de Internet, respuesta afirmativa a P316$5; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_proposito_6	Propósito de uso de Internet, respuesta afirmativa a P316$6; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %

Campo	Descripción / codificación	Falt.
tic_proposito_7	Propósito de uso de Internet, respuesta afirmativa a P316$7; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_proposito_8	Propósito de uso de Internet, respuesta afirmativa a P316$8; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_proposito_9	Propósito de uso de Internet, respuesta afirmativa a P316$9; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_proposito_10	Propósito de uso de Internet, respuesta afirmativa a P316$10; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_proposito_11	Propósito de uso de Internet, respuesta afirmativa a P316$11; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_proposito_12	Propósito de uso de Internet, respuesta afirmativa a P316$12; descriptivo entre usuarios, excluido del modelo supervisado.	0,0 %
tic_habilidades_digitales_n	Conteo de tareas informáticas afirmativas reportadas (P316C1-P316C10); predictor exploratorio aproximado, no evaluación de competencia certificada.	85,6 %
tic_uso_computadora_ult3m	Uso de computadora/laptop/tablet en los últimos tres meses (derivado de P316B; 1=sí, 0=no).	66,6 %
ingreso_hogar_percapita	INGHOG2D / MIEPERHO.	0,0 %
gasto_hogar_percapita	GASHOG2D / MIEPERHO.	0,0 %
rural	Indicador derivado: estratos 6, 7 u 8; verificar codificación anual del marco muestral.	0,0 %
grupo_conglomerado	CONGLOME conservado como texto; grupo de partición para evitar solapamiento entre train/test.	0,0 %

Continuación del diccionario de variables.

Campo	Descripción / codificación	Falt.
factor_expansion	FACTOR07 del módulo Sumaria/educación usado como peso cuando existe.	0,0 %

6. Consideraciones para su interpretación

- Los indicadores ESCALE representan contexto por distrito; no son mediciones del establecimiento individual.
- El objetivo documentado es no uso mensual de Internet, no rezago escolar ni habilidades digitales demostradas.
- Altitud, equipamiento de computadoras y conectividad escolar no están sustentados en los archivos entregados.
- La auditoría conserva las llaves como texto y evita divulgar códigos personales en anexos públicos.

Trazabilidad. 01_resumen_dataset.json; 01_diccionario_variables.csv; 01_calidad_datos.csv; 01_control_cruces.json; 01_control_fuga_datos.json.