UNIVERSIDAD PERUANA UNIÓN (UPEU)

Facultad de Ingeniería y Arquitectura

E.P. Ingeniería de Sistemas



CURSO: Inteligencia Artificial

ESTUDIANTES:

Russbell Daniel Cari Mamani

DOCENTE:

Angel Rosendo Condori Coaquira

ANEXO-AUDITORIA-RUBRICA-REPRODUCIBILIDAD

CONTROL DOCUMENTAL · EVIDENCIAS TRAZABLES

ANEXO C | AUDITORÍA DE LA RÚBRICA Y REPRODUCIBILIDAD

Matriz de verificación elaborada a partir de la auditoría de Codex y la guía del ingeniero (20 puntos). No constituye predicción de nota, aprobación oficial ni sustitución de la evaluación docente.

1. Matriz de cumplimiento y puntos de atención

01. Integración ENAHO 100/200/300/Sumaria — Parcial/verificado

Evidencia: Dataset, código y resumen; llaves documentadas

Límite: No se recontaron etapas originales en esta exportación

02. ESCALE matrícula 2025 enlazada con padrón — Verificado parcial

Evidencia: 54,038/54,038 servicios enlazados por COD_MOD+ANEXO

Límite: No permite identificar escuela ENAHO individual

03. Clustering, dos algoritmos y k 2–6 — Verificado

Evidencia: CSV métricas con Silhouette, DB, CH; PCA y silueta existentes

Límite: Perfiles exploratorios; faltan variables escolares ausentes

04. PCA 2D — Verificado

Evidencia: Figura clusters_pca existente

Límite: Figura de origen conservada, dpi de fuente no elevado

05. Clasificación baseline + tres modelos — Verificado

Evidencia: Comparación y GroupKFold guardados

Límite: Falta validación estadística por diseño muestral

06. Test aislado por CONGLOME — Verificado

Evidencia: auditoria_split_conglomerado.json, cero intersecciones

Límite: Registros son evidencia del pipeline guardado

07. ROC/PR/matriz/calibración — Parcial

Evidencia: ROC/PR/calibración y matriz exportadas; curvas derivadas con modelo guardado

Límite: La recalibración es una derivación de auditoría; no reentrenamiento

08. SHAP summary, 2 dependencias, 2 casos — Parcial

Evidencia: Figuras y JSON existentes

Límite: Salida SHAP no declara escala explícitamente; casos anonimizados

09. Altitud, equipos, conectividad escolar — No verificable / ausente

Evidencia: Limitación explícita en auditoría y reportes

Límite: No inferir ni inventar

10. Guía original PDF del docente — Consultada (7 páginas)

Evidencia: cotejo de fases, requisitos y rúbrica máxima 20 puntos

Límite: La nota de entrega depende de evaluación docente; esta auditoría no predice calificación

2. Correspondencia con los criterios del ingeniero

- Ingeniería de datos y prevención de fuga (5 pts): llaves compuestas documentadas, split por CONGLOME sin superposición y transformaciones dentro de folds; no hay conteos completos de cada filtro original.
- Clustering y perfilamiento (4 pts): dos algoritmos, k=2–6, selección por silueta, métricas complementarias y PCA; interpretación exploratoria.
- Clasificación supervisada (5 pts): baseline más tres modelos, GroupKFold, métricas ROC/PR/F1, control de desbalance y factor muestral; falta inferencia de diseño complejo.
- XAI–SHAP (3 pts): global, dos dependencias y dos waterfalls; la escala de salida SHAP no está fijada explícitamente.
- Redacción y reproducibilidad (3 pts): repositorio y código fuente en proyecto original, PDF preexistente de cinco páginas y resultados tabulares; referencias institucionales requieren revisión editorial.

3. Estructura de archivos respaldatorios

Sección	Archivos principales	Uso
Datos	01_resumen_dataset.json; 01_diccionario_variables.csv	Método, calidad, diccionario
Cruces	01_control_cruces.json; 01_control_fuga_datos.json	Llaves y GroupShuffleSplit
Clustering	02_resultados_clustering.json; 02_comparacion_algoritmos.csv	Selección y perfiles
Clasificación	03_comparacion_modelos.csv; 03_validacion_groupkfold.csv	CV y test
SHAP	04_resumen_shap.json; 04_importancia_variables.csv	Atribuciones y ejemplos
Manifiesto	06_manifest_archivos.json; 06_reproducibilidad.json	Hashes, rutas y versiones

4. Reproducción técnica

La auditoría se ejecutó sobre artefactos persistidos; no vuelve a entrenar modelos. El proyecto canónico permanece en entregables/, con scripts src/pipeline.py, notebook notebooks/01_evaluacion_brecha_digital.ipynb, dataset data/processed/dataset_enaho_escale_2025.parquet y modelo outputs/models/modelo_ganador.joblib.

Entorno documentado: Windows 10; Python 3.12.14; scikit-learn 1.9.1; pandas 2.3.3; SHAP 0.54.1; NumPy 2.5.4.

Semilla: random_state=42 en los procedimientos documentados.

Para regenerar únicamente las curvas derivadas, desde la raíz del workspace original de Codex (data_limpia) se utiliza el script EVIDENCIAS_FINALES_IA_2025/06_REPRODUCIBILIDAD/generar_evidencias.py con el intérprete de .venv. No ejecutar directamente src.pipeline solo para generar el paquete, porque puede reescribir los artefactos originales.

Ejemplo de comando documentado:

```
.\.venv\Scripts\python.exe .\EVIDENCIAS_FINALES_IA_2025\06_REPRODUCIBILIDAD\generar_evidencias.py
```

5. Limitaciones que deben declararse en defensa

- El target es ausencia de uso de Internet en el último mes; no desempeño escolar, alfabetización digital ni acceso escolar.
- La vinculación escuela-estudiante no está disponible; indicadores ESCALE se utilizaron agregados por distrito.
- La ausencia de información de altitud, equipos y conectividad de escuelas impide analizarlos como predictores confirmados.
- Las métricas ponderadas no deben combinarse sin advertencia con la matriz de conteos no ponderada.
- La calibración fue derivada con modelo guardado; no se acredita reentrenamiento ni recalibración.
- La validez externa y los intervalos de confianza del diseño complejo de la encuesta no se establecieron aquí.

Trazabilidad. 00_estado_cumplimiento_rubrica.csv; README_PARA_CHATGPT.md; 06_reproducibilidad.json; 06_instrucciones_ejecucion.md.