BRECHA DIGITAL Y EDUCACIÓN EN PERÚ: ANÁLISIS CON ENAHO-ESCALE 2025

Artículo técnico · ENAHO 2025 · Validación por conglomerados · Semilla 42

Resumen

Se integraron los módulos ENAHO 100, 200, 300 y Sumaria 2025 con el padrón ESCALE y matrícula 2025 disponibles en el proyecto. La población analítica comprende 17,992 escolares asistentes de 6 a 17 años con respuesta válida sobre uso de Internet. El resultado es no haber usado Internet el mes anterior (prevalencia 25.6%). Se compararon dos algoritmos de clustering y cuatro clasificadores con separación por CONGLOME. RandomForest obtuvo ROC-AUC ponderado 0.828, PR-AUC 0.571 y F1 macro 0.712 en test agrupado. La interpretación se limita al uso reciente de Internet; las medidas ESCALE son contexto distrital y no identifican la escuela del estudiante.

Palabras clave: brecha digital; educación; ENAHO; ESCALE; agrupamiento; clasificación; SHAP.

1. Introducción

La brecha digital escolar combina condiciones del hogar, uso de tecnologías y oferta educativa local. Este análisis responde a una pregunta predictiva acotada: entre escolares asistentes de 6 a 17 años, ¿qué características ayudan a ordenar a quienes no reportaron uso de Internet en el mes previo? La respuesta es una asociación del modelo, no una estimación causal ni una medición de aprendizaje.

Fuentes y cruce

Las llaves personales se conservaron como texto. ENAHO 200 y 300 se enlazaron por identificadores de persona; los módulos 100 y Sumaria por llaves del hogar. Padron y matrícula escolar se vincularon por COD_MOD+ANEXO y se agregaron por UBIGEO. La auditoría registra 54038/54038 servicios enlazados en los archivos disponibles. Padlocal se usó para contar locales por UBIGEO y revisar CODLOCAL. ENAHO no tiene COD_MOD/CODLOCAL, por lo que el indicador ESCALE es territorial, no individual.

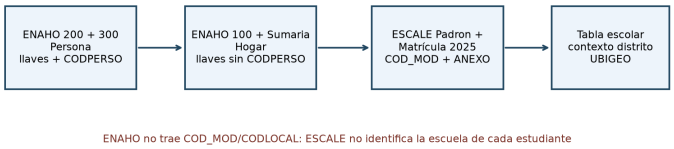


Figura 1. Llaves de integración y límite del enlace escolar.

2. Datos y metodología

El objetivo vale 1 para P314A=2 y 0 para P314A=1, entre personas de 6 a 17 años con P307=1. Se conservaron edad, grado, sexo, lengua materna, características del hogar, geografía y medidas distritales disponibles. P1121 se interpreta como electricidad del hogar, no como conectividad; P1144 identifica Internet doméstico.

Variables TIC y calidad de datos

Se incorporaron P314B (lugar), P314D (frecuencia), P316 (propósito), P316B (uso de computadora/tableta) y P316C1-C10 (tareas digitales declaradas). Los lugares, frecuencia y propósitos se describen, pero no se usan como predictores porque dependen de haber usado Internet y podrían filtrar el resultado. P316B y el conteo de tareas P316C entran al análisis predictivo con imputación y señalización de faltantes dentro de cada fold. Las tareas son una aproximación autodeclarada, no una prueba de destreza.

Los porcentajes de faltantes por variable están en el diccionario analítico; N válido y faltante por ítem TIC están en la tabla de frecuencias. El tratamiento no aprende parámetros con el test: imputación, escalado y one-hot se ajustan dentro del pipeline de cada fold.

Variable analítica	Faltantes (%)
P1144	0.0
P314A	0.0
P314D	25.6
P316B	66.6
agua_potable	16.7
esc_matricula_primaria_2025	0.0
esc_n_locales_padlocal	0.0
esc_ratio_alumno_docente	0.0
rezago_escolar_anios	4.1
saneamiento_red_publica	0.0
tic_frecuencia_uso_cluster	0.0
tic_habilidades_digitales_n	85.6
tic_uso_computadora_ult3m	66.6

P316B y el conteo de tareas tienen faltantes altos por saltos y preguntas condicionadas. No se convierten a "no"; la imputación con indicadores limita la fuga entre folds, pero el modelo puede aprender el patrón de respuesta y por eso estas asociaciones se interpretan con cautela.

Integración ESCALE

Padlocal.dbf se utilizó para contar locales por UBIGEO y comprobar coincidencia de CODLOCAL con Padron. No tiene coordenadas numéricas ni altitud. El Padron aporta agregados disponibles de matrícula, docentes, gestión y coordenadas. Los archivos locales no permiten derivar altitud, equipamiento informático o conectividad escolar; no se imputan ni infieren. Sin COD_MOD/CODLOCAL en ENAHO, no se atribuye la escuela concreta a cada menor.

Clustering

Se tomó una muestra reproducible de hasta 4,000 filas, con imputación, escalado y codificación, y se compararon K-Means y Agglomerative para k=2 a 6 sobre 20 componentes principales. La solución con mayor silueta fue Agglomerative, k=2 (silueta=0.314; Davies-Bouldin=1.326; Calinski-Harabasz=683.4). Los perfiles incluyen ingreso y gasto per cápita, ratio alumnos/docente distrital, frecuencia TIC P314D (0=no uso), años de rezago y servicios básicos. P314D se limita al clustering para evitar fuga en clasificación. Los nombres se basan en ruralidad y no uso relativo, con medias detalladas abajo; son descriptivos y exploratorios.

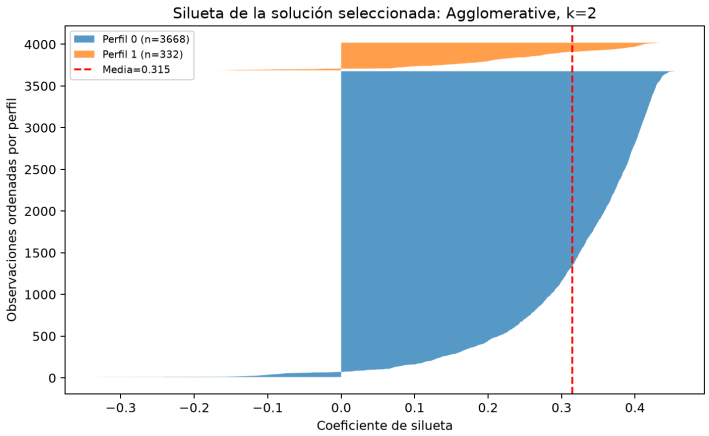


Figura 2. Coeficientes de silueta de la solución seleccionada.

3. Resultados de perfiles y clasificación

Algoritmo	k	Silueta	Davies-B.	Calinski-H.
Agglomerative	2	0.314	1.326	683.4
KMeans	2	0.306	1.409	751.6
Agglomerative	3	0.199	2.056	541.7
Agglomerative	4	0.157	2.140	508.7
KMeans	6	0.153	1.751	541.0
KMeans	5	0.138	1.904	559.1
KMeans	4	0.135	2.055	583.5
KMeans	3	0.123	2.248	638.2
Agglomerative	6	0.122	1.838	480.4
Agglomerative	5	0.099	2.039	484.9

Perfil	n	No uso	Frecuencia TIC	Ratio A/D	Ingreso pc (miles)	Rezago (años)	Agua potable	Saneam. red
Mayor ruralidad y no uso cercano al promedio (exploratorio)	3668	26.3%	0.92	14.3	9.2	0.49	0.68	0.53
Menor ruralidad y menor no uso reciente (exploratorio)	332	16.0%	0.90	17.9	11.9	0.48	0.97	0.93

La distribución observada es Mayor ruralidad y no uso cercano al promedio (exploratorio): n=3668, Menor ruralidad y menor no uso reciente (exploratorio): n=332. La tabla permite comprobar las diferencias de ruralidad, Internet del hogar, no uso, habilidades declaradas, rezago y acceso a servicios. La silueta orienta la separación geométrica; no valida por sí sola utilidad educativa ni convierte los nombres exploratorios en categorías oficiales.

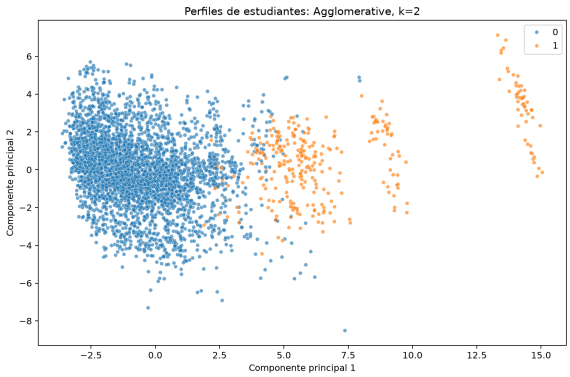


Figura 3. Proyección PCA bidimensional; solo visualización.

Clasificación y prevención de fuga

GroupShuffleSplit aisló 20% de conglomerados para prueba; GroupKFold comparó candidatos en entrenamiento. Se excluyeron P307 y P314A de predictores. P314B, P314D y P316 tampoco entran al modelo por su condicionamiento posterior al resultado. P316B y P316C sí se incluyen como predictores observados, con faltantes tratados dentro de cada fold. Se evaluaron una regresión logística base, Random Forest, Extra Trees e HistGradientBoosting; FACTOR07 ponderó ajuste y métricas cuando estuvo disponible.

4. Desempeño predictivo

Modelo	AUC CV	DE CV	AUC test	PR-AUC	F1 macro	Precisión	Recall
RandomForest	0.819	0.009	0.828	0.571	0.712	0.483	0.700
HistGradientBoosting	0.818	0.010	0.835	0.585	0.701	0.474	0.662
ExtraTrees	0.817	0.009	0.822	0.569	0.690	0.441	0.747
LogisticRegression	0.804	0.007	0.812	0.528	0.676	0.424	0.732

RandomForest obtuvo el mejor AUC medio de validación por conglomerado (0.819; DE 0.009). En el test aislado, ROC-AUC=0.828 y PR-AUC=0.571, frente a prevalencia de 25.6%. Con umbral 0.5, precisión=0.483 y recall=0.700; este umbral no representa una decisión de política calibrada a costos.

La matriz de conteos registra TN=2,110, FP=591, FN=206 y TP=678. Los falsos negativos son casos de no uso no detectados; los falsos positivos priorizarían casos que sí reportaron uso. La tabla ponderada también está disponible para distinguir conteos de escala poblacional.

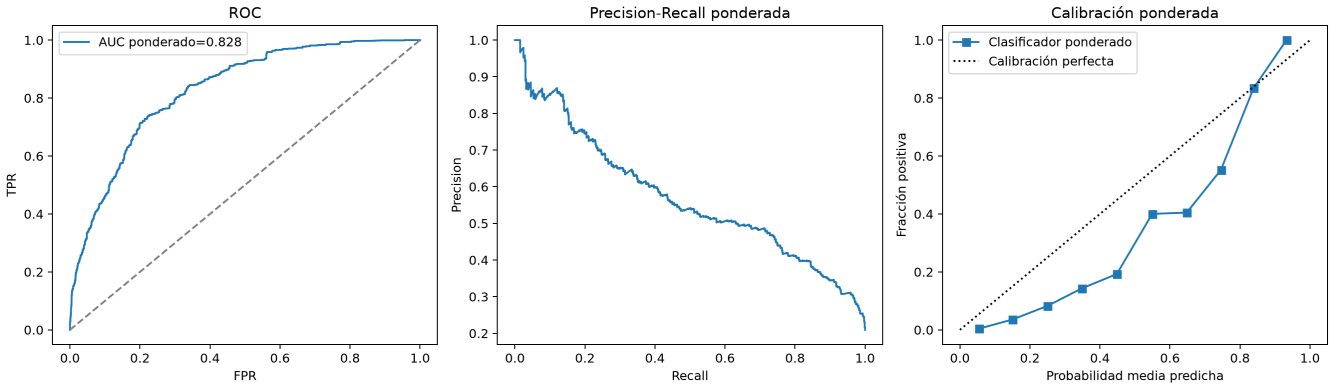


Figura 4. Curvas ROC, precisión–recall y calibración del mejor modelo en test agrupado.

Importancia global SHAP

Atributo	Media |SHAP|
edad	0.0498
P308A_3.0	0.0434
P308A_2.0	0.0405
gasto_hogar_percapita	0.0360
missingindicator_tic_uso_computadora_ult3m	0.0285
ingreso_hogar_percapita	0.0199

edad y P308A_3.0 encabezan la media absoluta SHAP en esta ejecución. La importancia mide magnitud media de contribución del modelo, no dirección causal. Las variables ESCALE de coordenadas describen patrones geográficos y no deben interpretarse como efectos propios de la escuela del escolar.

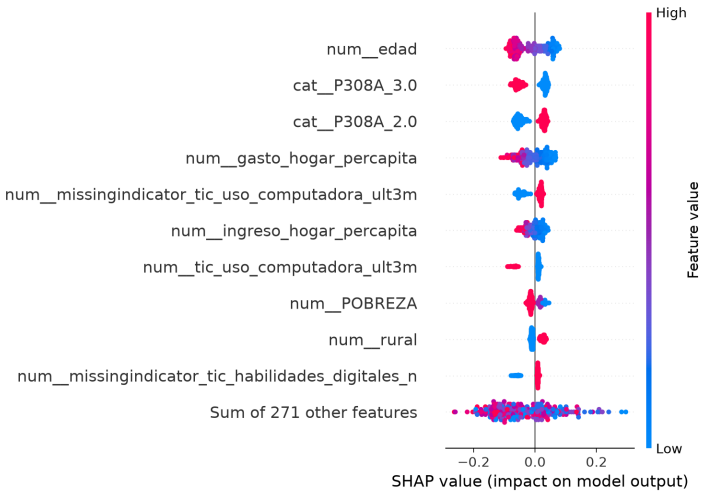


Figura 5. Distribución y dirección de las contribuciones SHAP globales.

5. Dependencias, casos locales y discusión

Las dependencias seleccionadas analizan P1144 con lengua materna (indicador de Quechua) y con el ratio distrital alumnos/docente. En el primer gráfico, el color separa la categoría Quechua codificada frente a otras observaciones; en el segundo, el color muestra el ratio contextual. La dispersión representa contribuciones aprendidas condicionadas a los otros predictores, y no demuestra que modificar conexión o ratio cause cambios en el resultado.

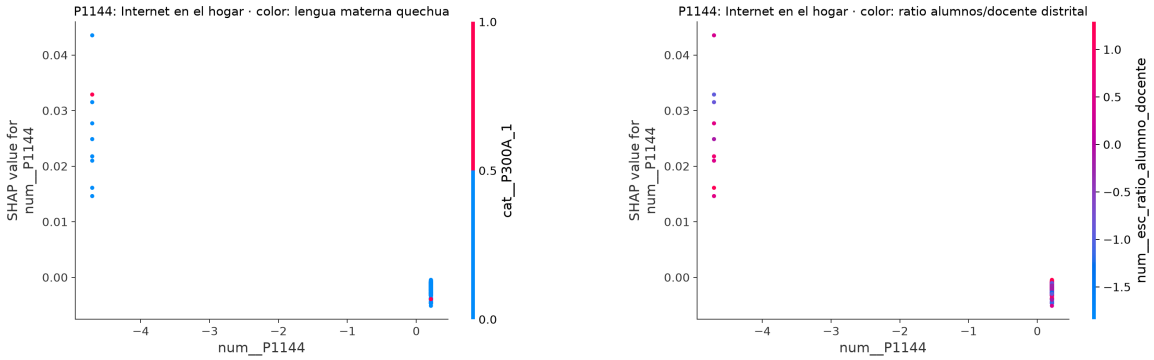


Figura 6. Dependencia de P1144: interacción exploratoria con lengua materna y ratio distrital.

Los waterfall locales describen dos predicciones correctas del modelo RandomForest. En el caso alto (probabilidad 0.946), las mayores contribuciones fueron gasto_hogar_percapita (+0.041), edad (+0.034), rural (+0.031); valores SHAP positivos elevaron la salida para no uso. En el caso bajo (probabilidad 0.006), destacaron tic_uso_computadora_ult3m (-0.054), edad (-0.053), missingindicator_tic_habilidades_digitales_n (-0.046); valores SHAP negativos redujeron esa salida. Son explicaciones de dos observaciones y no describen todos los casos.

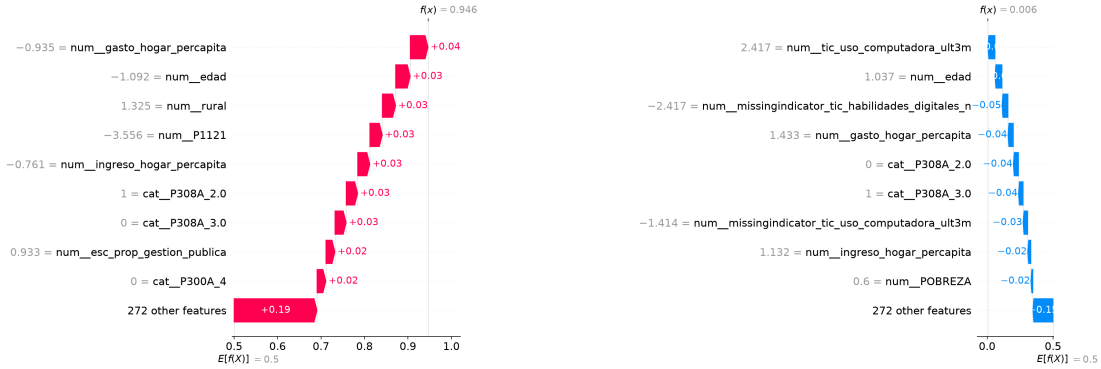


Figura 7. Waterfall: caso correctamente clasificado con mayor y menor probabilidad predicha entre los explicados.

Conclusiones y limitaciones

El pipeline produce una comparación predictiva reproducible con separación por conglomerados y evidencia explícita de las variables usadas y excluidas. El uso mensual de Internet es una medida concreta, más estrecha que conectividad estable, destreza digital o aprendizaje. Las tareas P316C permiten describir acciones autodeclaradas. ESCALE agrega contexto por UBIGEO: el Padlocal existente no ofrece coordenadas numéricas y la llave institucional no aparece en ENAHO. Los datos disponibles tampoco sustentan altitud, equipamiento o conectividad escolar; estos aspectos deben presentarse como limitaciones.

Se recomienda usar las estimaciones para orientar diagnóstico territorial, validar perfiles con actores locales y no asignar recursos individuales automáticamente. Una evaluación externa y mediciones escolares con llave compatible serían necesarias para extender las conclusiones.

Referencias: INEI, *Diccionario de Datos ENAHO 2025*, https://proyectos.inei.gob.pe/iinei/srienaho/Descarga/DocumentosMetodologicos/2025-55/20_Diccionario_2025.pdf; MINEDU, *Catálogo Censo Educativo 2025*, https://escale.minedu.gob.pe/uee/-/document_library_display/GMv7/view/10632985; Lundberg y Lee (2017), SHAP; Pedregosa et al. (2011), scikit-learn.